#MLorDS

第三部分：你好，阳光！——隐含狄利克雷分布

Sunshine 公司开发了一系列产品——这包括婴儿奶嘴、吹风机和微波炉。经过一段时间后，公司发现婴儿奶嘴销售很好，但是微波炉和吹风机却遭遇了巨大的失败。公司负责人很不甘心，他爬取了用户对产品的评分星级和评论内容，试图从中找到挽回的可能。如何从浩如烟海的用户评论中找出核心的词汇、挑选出最具代表性的主题呢？——LDA 就是一种可行的方法。

本章的标题和导入文字均改编自 2020 MCM Problem C

What is LDA?——Dirichlet Distributions

LDA 是一个生成模型，我们实际是希望调整 LDA 中的参数，使得由模型生成的文章和真实的文章最为接近。

那么这个概率是由四项连乘式得到：四项连乘式中有两个 Dirichlet分布和两个多项分布，形象地来说，这四项分别代表着制造两个骰子和投掷两个骰子的过程。

$$P(\boldsymbol{W},\boldsymbol{Z},\boldsymbol{\theta},\boldsymbol{\varphi};\alpha,\beta)=\prod_{j=1}^{M}P(\theta_j;\alpha)\prod_{i=1}^{K}P(\varphi_i;\beta)\prod_{t=1}^{N}P(Z_{j,t}\mid\theta_j)\,P(W_{j,t}\mid\varphi_{Z_{j,t}})$$

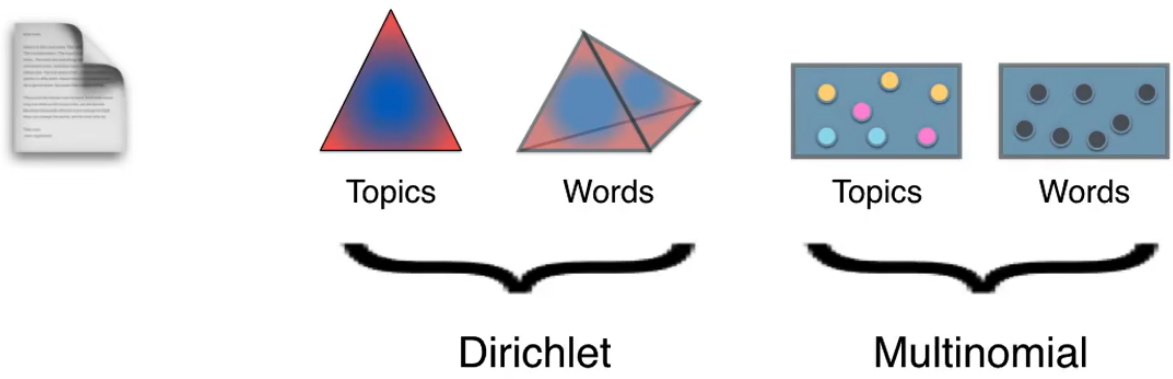

我们分别来解说这四个分布：

- 第一个 Dirichlet 分布——描述 Doc-Topics 的关系：将文章和主题联系起来。根据给定的参数 α，这个 Dirichlet分布生成一个向量 θ_j，向量中的每一个分量都是一个主题出现的概率。例如，生成的 $\theta_j=[0.7,0.1,0.2]$ 意味着科学、政治、体育出现的概率是 0.7，0.2，0.1。形象地来说，这一步中，我们由 Dirichlet 分布制造了一个三面骰，每个面都是一个主题，掷出三个面的概率分别就是 0.7,0.2,0.1。上面方程中的 $P(\theta_j;\alpha)$ 代表着在 α 参数下，Dirichlet 分布给出主题概率向量 θ_j 的概率。
- 第一个多项分布——用于确定 Topics。在这一步中，我们抛掷 t 次刚才制造的骰子，从而得到 t 个不同的主题，第 t 次得到的主题被记作 $Z_{j,t}$。上面方程中，由概率向量 θ_j 生成主题 $Z_{j,t}$ 的概率被记作 $P(Z_{j,t}|\theta_j)$
- 第二个 Dirichlet 分布——描述 Topics-Words 的关系：将之前生成的一系列主题和单词联系起来。根据给定的参数 β，这个 Dirichlet 分布针对可能取到的 K 个主题生成 K 个向量 ϕ_i，向量中的每一个分量都是指定主题下每一个单词出现的概率。形象地来说，这相当于又制造了一个多面

骰，每个面都是一个单词。上面方程中，在 β 参数下，对第 i 个主题生成出单词概率向量 ϕ_i 的概率记为 $P(\phi_i;\beta)$

- 第二个多项分布——用于确定 Words。对第 t 次得到的主题 $Z_{j,t}$，投掷一次单词的“骰子”，生成出一个单词。在概率向量 $\phi_{Z_{j,t}}$ 下生成单词 $W_{j,t}$ 的概率被记为 $P(W_{j,t}|\phi_{Z_{j,t}})$

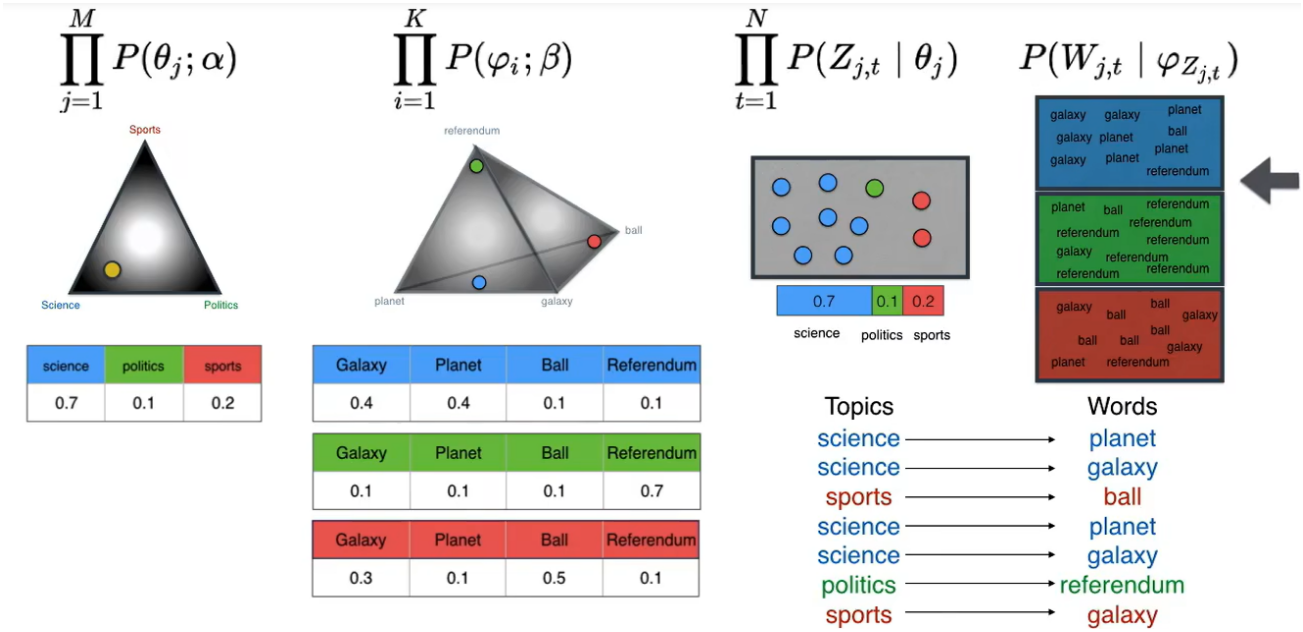

另外，提请注意：你会发现如果按照上面的表述来写式子，和最初的方程是对不上的，这是因为，上面的四步只是按照逻辑顺序写的，但是在实际生成文章的时候，步骤和上面不太一样

我们说一下这个概率的方程是怎么写出的，也就是说，我们要求解一个在参数 α,β 下生成了一系列主题概率分布 θ、一系列单词概率分布 ϕ、一系列主题 Z 和一系列单词 W 的概率。
首先，对于指定的文档 j，我们进入准备阶段：在准备阶段中，我们首先制造第一枚骰子——生成文章主题的概率分布 θ_j，这会导致概率乘上一项 $P(\theta_j;\alpha)$；然后，对于所有可能的 K 个主题，先把每个主题对应的单词概率分布生成好，这会导致概率乘上一项连乘式 $\prod_{i=1}^{K} P(\phi_i;\beta)$，至此，准备阶段结束。
下面，我们进入文章生成阶段：一篇文章中共需要生成 N 个单词，对第 t 个 单词首先生成主题 $Z_{j,t}$，再根据主题生成单词 $W_{j,t}$，这会导致概率乘上一项连乘式 $\prod_{t=1}^{N} P(Z_{j,t}|\theta_j)P(W_{j,t}|\phi_{Z_{j,t}})$
最后，由于一共有 M 篇文章，所以在概率的最前面还要加一个连乘符号 $\prod_{j=1}^{M}$
我们写下的表达式就是：

$$P(\theta,\phi,Z,W;\alpha,\beta)=\prod_{j=1}^{M}P(\theta_j;\alpha)\prod_{i=1}^{K}P(\phi_i;\beta)\prod_{t=1}^{N}P(Z_{j,t}|\theta_j)P(W_{j,t}|\phi_{Z_{j,t}})$$

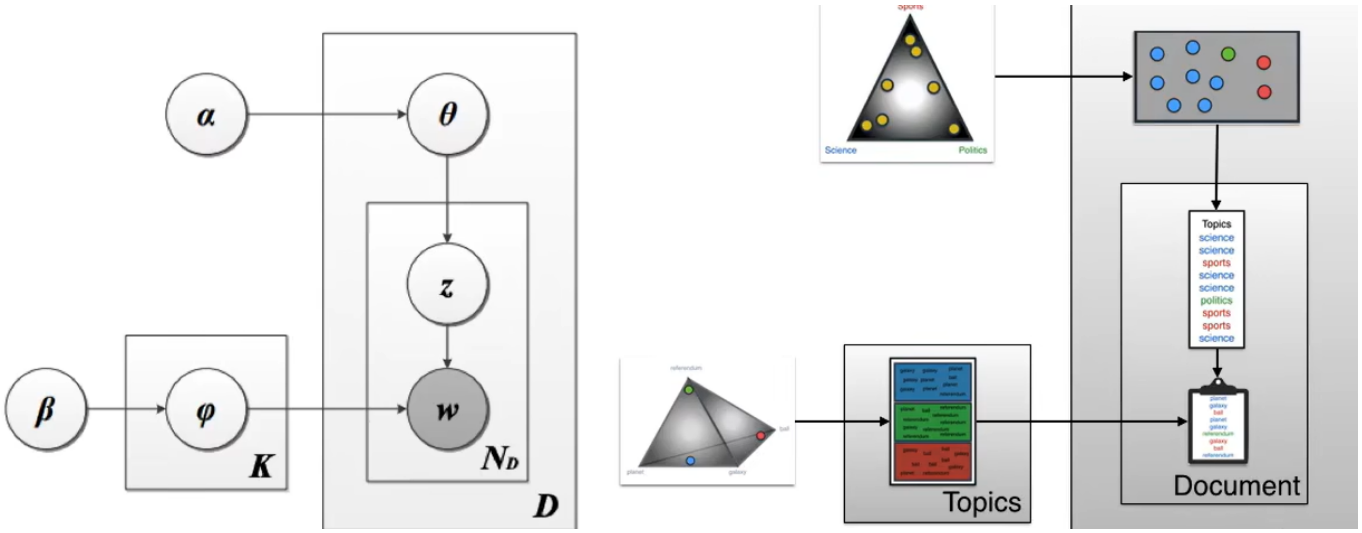

How to train LDA?—— Gibbs Sampling